

CMT와 Vision Mamba의 심층 비교 분석: CNN-Transformer 하이브리드와 상태공간 모델의 원리적 대비

김철희, 이강국, 심규성
한경국립대학교 컴퓨터응용수학부

e-mail : kkim9846@hknu.ac.kr, rkdrnr9945@hknu.ac.kr, kyusung.shim@hknu.ac.kr

A Comparative Analysis of CMT and Vision Mamba: CNN-Transformer Hybrid vs. State Space Model

Choelhui kim, Gangguk Lee, and Kyusung Shim

Hankyong National University, School of Computer Engineering and Applied Mathematics

Abstract

This paper presents a comparison of CMT (2022) and Vision Mamba (Vim, 2024), two architectures designed to address the limitations of Vision Transformers (ViT). CMT combines self-attention with depth-wise convolutions and a multi-stage pyramid structure to capture local and multi-scale features, whereas Vision Mamba replaces self-attention with a bidirectional selective state space model (SSM) to achieve linear sequence complexity. We analyze their computational complexity, receptive field characteristics, and learning behavior, and identify the cross-over point where SSM-based modeling becomes more efficient. Experimental and theoretical analysis shows that the two approaches are complementary, motivating recent hybrid architectures such as VMamba.

I. 서론

Vision Transformer(ViT)는 이미지 분류에서 큰 성공을 거두었으나, 고정된 16×16 패치로 인한 지역 구조 손실, 단일 스케일 표현의 한계, 그리고 입력

길이에 대한 $O(N^2)$ 복잡도라는 세 가지 본질적 한계를 갖는다. 본 논문은 이러한 한계를 정반대 방향에서 해결한 두 대표 모델을 비교한다. CMT^[1]는 Transformer에 컨볼루션의 2D 지역성을 결합한 하이브리드 접근이며, Vision Mamba(Vim)^[2]는 Self-attention을 양방향 선택적 상태공간 모델(Selective State Space Model: SSM)로 완전히 대체한다.

두 모델은 동일한 문제 의식에서 출발하지만, 'Attention을 보완할 것인가, 대체할 것인가'라는 가정에서 갈라진다. 본 논문에서는 아키텍처 구조, 복잡도의 이론적 유도, 수용 영역(Receptive Field), ZOH 이산화의 의미, 실측 성능 차이의 원인을 체계적으로 분석한다.

II. 본론

2.1 CMT 아키텍처

CMT는 ResNet/EfficientNet 스타일의 계층적 4-stage 백본으로, 각 stage는 LPU, LMHSA, IRFFN 세 모듈로 구성된 블록을 반복한다. Local Perception Unit(LPU)는 3-by-3 Depth-wise Convolution에 잔차를 더한 형태로, 패치 내부의 2D 구조와 위치 정보를 동시에 주입한다. 이를 수학적으로 나타내면 식 (1)과 같다.

$$\text{LPU}(x) = \text{DWConv}(X) + X \quad (1)$$

Lightweight Multi-Head Self-Attention(LMHSA)는 Key/Value에 Stride k의 Depth-wise Conv를 적용해 공간 크기를 $1/k^2$ 로 축소한 뒤 Attention을 수행하며, 학습 가능한 상대 위치 bias B를 도입한다. 이를 수학적으로 나타내면 식 (2)와 같다.

$$\text{LightAttn}(Q,K,V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + B\right)V' \quad (2)$$

Inverted Residual FFN(IRFFN)은 MobileNetV2의 Inverted Residual 구조를 차용해 1×1 Conv로 확장, 3×3 DWConv로 locality 주입, 1×1 conv로 축소를 수행한다. Stage별 Reduction Ratio는 $k = 8, 4, 2, 1$ 로 설계되어, 해상도가 높은 초기 Stage에서는 Attention 비용을 강하게 압축하고 후기 Stage에서는 Full Attention을 허용한다.

2.2 Vision Mamba 아키텍처

Vim은 ViT와 유사한 평면 구조에서, 입력 시퀀스를 LayerNorm 후 두 분기(x, z)로 나누어 처리한다. x 에 대해 Forward와 Backward 두 방향으로 1D conv, SiLU, 그리고 입력 의존적인 B, C, Δ 투영을 거쳐 SSM 연산을 수행한 뒤 z 게이팅으로 결합한다. 핵심 연산은 식 (3)과 식(4)와 같다.

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t \quad (4)$$

$$y_t = Ch_t \quad (5)$$

여기서 $\bar{A}$, $\bar{B}$ 는 연속 시간 시스템의 Zero-Order Hold(ZOH) 이산화 결과이다. ZOH는 한 토큰 구간 Δ 동안 입력을 일정하다고 가정하면 식 (6), 식(7)과 같다.

$$\bar{A} = \exp(\Delta A) \quad (6)$$

$$\bar{B} = (\Delta A)^{-1}(\exp(\Delta A) - I)\Delta B \quad (7)$$

Δ 는 입력 의존적이므로 매 토큰마다 시간 스케일이 다르게 적용된다. 이를 수학적으로 표현하면 식 (8)과 같다.

$$(\Delta_t = \text{softplus}(\text{Linear}(x_t) + \theta)) \quad (8)$$

이는 정보가 풍부한 토큰에서는 Δ 를 작게 만들어 상태에 오래 머무르게 하고, 무관한 토큰에서는 Δ 를 크게 하여 빠르게 잊는 Selective Mechanism을 형성한다. 양방향성은 단방향 SSM이 갖는 '미래 정보 비가시성' 문제를 해결하여, Ablation에서 ImageNet 정확도 $73.2 \rightarrow 73.9\%$, ADE20K $32.3 \rightarrow 35.9$ mIoU의 향상을 제공한다.

2.3 복잡도 유도와 Cross-over Point

입력 토큰 수 M, 채널 d, SSM 상태 차원 N에 대해 표준 Self-attention의 복잡도는 $4Md^2 + 2M^2d$ 이며,

CMT-LMHSA는 K/V를 $1/k^2$ 로 축소함으로써 $2Md^2(1+1/k^2) + 2M^2d/k^2$ 가 된다. 즉 CMT는 Quadratic 항을 제거하지 못하고 계수만 줄었다. 반면 Vim의 한 방향 SSM은 8MDN으로 M에 대해 선형이다. Self-attention의 Quadratic 항이 Linear 항을 추월하는 지점은 $2M^2d = 4Md^2 \Rightarrow M = 2d$ 이며, $d = 384$ 일 때 $M \approx 768$ 이다. 이는 입력 해상도 약 384×384 ($M = 576$)과 512×512 ($M = 1024$) 사이에서 Self-attention의 복잡도가 폭발적으로 증가함에 따라 고해상도로 갈수록 SSM이 매우 유리해지는 것을 의미이다. 표 1은 해상도에 따른 Self-attention, CMT, Vim 아키텍처의 출력 결과이다.

표 1. 시퀀스 길이별 Attention/CMT/Vim의 추정 FLOPs
(D=384, N=16)

M	Self-attention	CMT(k=2)	Vim
196	0.14G	0.11G	0.02G
1024	1.41G	0.68G	0.10G
4096	15.21G	4.41G	0.40G
6084	32.55G	9.31G	0.60G

III. 성능평가

3.1 수용 영역(Receptive Field)의 본질적 차이

CMT의 수용 영역은 Convolution의 점진적 확장, LMHSA의 (축소된) 전역 Attention, IRFFN의 추가 Locality라는 세 메커니즘의 중첩으로 형성된다. 결과적으로 Effective Receptive Field(ERF)는 2D Gaussian-like 분포를 갖는다. 반면 Vim의 양방향 SSM은 한 블록 통과만으로 시퀀스 전체가 수용 영역에 들어오지만, ERF는 $\bar{A}^k$ 의 지수 감쇠에 의해 결정되어 1D Scan 방향에 정합된 Anisotropic을 갖는다. Row-major Flatten시 수직으로 인접한 픽셀이 시퀀스 상 W만큼 떨어지므로 2D 공간 구조가 부분적으로 왜곡된다는 약점이 있다. VMamba가 4방향 Scan을 도입한 동기이기도 하다.

3.2 Softmax Dilution과 큰 객체 처리

Self-attention은 가중치 합이 1이라는 제약 때문에 객체가 K개 토큰에 걸쳐 있으면 평균 가중치가 $1/K$ 로 희석된다. 반면 SSM은 객체 토큰을 만날 때마다 상태에 $B - x_t$ 가 누적 더해지므로 Dilution이 발생하지 않는다.

3.3 성능 차이의 분해

동일한 25M 이하 입력 파라미터 규모에서 CMT-S는 ImageNet 83.5%, Vim-S는 80.5%로 3.0%p 차이를 보인다. CMT 논문의 Ablation을 따라 분해하면, 계층적 4-stage 구조가 1.5%p, CNN stem이 0.5%p, LPU가 0.8%p, IRFFN이 0.6%p 기여한다. 즉 차이의 대부분은 CMT가 주입한 2D 지역성과 Multi-scale이라는 Inductive bias에서 발생하며, Vim에 동등한 구조적 Prior를 주입한 후속 모델(VMamba, LocalMamba)에서는 격차가 1%p 미만으로 좁혀진다. 한편 1024² 이상 고해상도에서는 Vim이 DeiT 대비 2.8배 이상의 FPS와 86.8% 메모리 할당 감소를 달성하며, gigapixel-위성·병리영상 등에서는 Vim만이 실용적이다.

표 2. CMT-S와 Vim-S의 아키텍처·연산 요약

항목	CMT-S	Vim-S
전체구조	계층적 4-Stage	평면적 단일 스케일
Stem	3×3 Conv 누적	16×16 patch
핵심연산	LPU+LMHSA+IRFFN	양방향 SSM
복잡도	O(N ²)	O(N)
위치정보	상대적 bias+DWConv	양방향+Selective Δ
ImageNet Top-1	83.5%	80.5%

3.4 수학적 등가성과 표현력

Sun 등^[3]의 분석에 따르면 SSM은 kernel을 $\bar{A}$ 의 누적곱으로 인수분해한 Linear Attention의 특수한 경우로 볼 수 있다. 따라서 표현력은 $SSM \subset Linear\ Attention \subset Softmax\ Attention$ 순으로 엄격히 포함되며, CMT의 LMHSA는 Softmax Attention 계열이므로 이론적으로는 Vim보다 표현력이 크다. 그러나 SSM의 정보 채널은 Hidden State $N=16$ 에 불과한 좁은 파이프이며, 매우 긴 시퀀스에서는 정보 병목이 발생할 수 있다. 이것이 Vim의 근본적 한계이자 N 확장·multi-head SSM 등 후속 연구의 동기가 된다.

IV. 결론 및 향후 연구 방향

본 논문은 CMT와 Vision Mamba를 아키텍처, 복잡도, 수용 영역, 이산화 기법, 수학적 패러다임의

다섯 축에서 비교하였다. CMT는 'Attention을 유지하되 CNN 지역성으로 보완'하는 하이브리드 접근의 정점에 있고, Vim은 'Attention 자체를 SSM으로 대체'하는 새로운 패러다임의 출발점이다. 두 접근의 차이는 본질적으로 인간이 설계한 Inductive bias 강도와 데이터로부터 학습되는 시간 스케일($\mathcal{L}$)의 일반성 사이의 Trade-off로 환원된다.

저해상도·표준 분류에서는 CMT가 우위이며, 1024² 이상 고해상도와 멀티모달 사전학습 시나리오에서는 Vim 계열이 압도적이다. 두 모델이 상호 보완적이라는 점은 VMamba, LocalMamba 등 '계층적 SSM 백본'이 빠르게 등장한 흐름으로 검증된다. 향후 연구로는 CMT의 Stage-wise Reduction을 SSM에 도입한 Hierarchical Vim, ERF의 Down-stream Task 영향에 대한 정량 측정, $\mathcal{L}$ 학습이 데이터 효율성에 미치는 영향에 대한 통계 실험을 실시할 예정이다.

참고문헌

- [1] J. Guo et al., "CMT: Convolutional Neural Networks Meet Vision Transformers," in Proc. CVPR, 2022.
- [2] L. Zhu et al., "Vision Mamba: Efficient Visual Representation Learning with Bidirectional State Space Model," in Proc. ICML, 2024.
- [3] Y. Sun et al., "Retentive Network: A Successor to Transformer for Large Language Models," arXiv:2307.08621, 2023.